

R21

GUIADO EN CLASE

Script integrador: auth.log a JSON

Programación para Ciberseguridad · Fase II · AD2026

Este reto reúne, en un solo script, casi todo lo visto en Fase II: lectura de logs, expresiones regulares, control de flujo, y normalización de datos a JSON. Es el equivalente en Bash del script de cierre que construiste con PowerShell al final de Fase I.

Objetivo: Construir `auditoria_auth.sh`: un script que analiza intentos de login fallidos en `auth.log` y genera un reporte en JSON con alertas por IP.

Instrucciones

1. Crea el script con el shebang y la validación del log:

```
#!/bin/bash
LOGFILE="/var/log/auth.log"
if [ ! -f "$LOGFILE" ]; then
    echo "Error: no se encontro $LOGFILE" >&2
    exit 1
fi
```

2. Cuenta los intentos fallidos y genera el JSON:

```
total_fallidos=$(grep -c "Failed password" "$LOGFILE")
echo "Total de intentos fallidos: $total_fallidos"

echo "[" > reporte_auth.json
grep "Failed password" "$LOGFILE" | awk '{
    printf "  {\n    \"fecha\": \"%s %s\", \"usuario\": \"%s\", \"ip\": \"%s\" },\n",
      $1, $2, $9, $11
}' >> reporte_auth.json
echo "]" >> reporte_auth.json
jq . reporte_auth.json
```

3. Agrega alertas por IP:

```
UMBRAL=5
grep "Failed password" "$LOGFILE" | awk '{print $11}' | sort | uniq -c | \
while read -r cuenta ip; do
    if [ "$cuenta" -ge "$UMBRAL" ]; then
        echo "ALERTA: $ip tiene $cuenta intentos fallidos"
    fi
done
```

Evidencias requeridas

- Screenshot del código completo de `auditoria_auth.sh`.
- Screenshot de la ejecución mostrando el conteo, el JSON generado y las alertas por IP.

Preguntas de reflexión

1. El umbral de 5 intentos está definido como una variable (`UMBRAL=5`). ¿Cuáles son las ventajas de definirlo así en vez de escribir el número directamente en la condición del `if`?
2. Este script genera un JSON con `awk`. ¿En qué situación sería preferible usar Python en vez de Bash para esta tarea?
3. Si el log de `auth.log` tiene varios millones de líneas, el script podría tardar mucho. ¿Qué cambiarías para que solo procese las últimas N líneas o las de las últimas 24 horas?