

R23

GUIADO EN CLASE

Web scraper de OSINT

Programación para Ciberseguridad · Fase III · AD2026

El web scraping es la base técnica del OSINT automatizado: recolectar información pública de forma sistemática sin tocar directamente la infraestructura del objetivo. `requests` obtiene el HTML y BeautifulSoup lo convierte en algo navegable.

Objetivo: Construir un scraper que extraiga todos los enlaces y correos electrónicos de una página web, guardando los resultados en JSON.

Instrucciones

1. Instala las dependencias en tu entorno virtual:

```
pip install requests beautifulsoup4
```

2. Construye el scraper en `r23_osint_scraper.py`:

```
import requests, re, json
from bs4 import BeautifulSoup

URL = "https://example.com"
respuesta = requests.get(URL, headers={"User-Agent": "Mozilla/5.0"}, timeout=10)
print(f"Status: {respuesta.status_code}")

sopa = BeautifulSoup(respuesta.text, "html.parser")
titulo = sopa.title.string if sopa.title else "Sin titulo"
enlaces = [a.get("href") for a in sopa.find_all("a") if a.get("href")]
correos = list(set(re.findall(r'[\w.+~]+@[~\w-]+\.[\w.-~]+', sopa.get_text()))))

resultado = {"url": URL, "titulo": titulo,
             "total_enlaces": len(enlaces), "correos": correos,
             "enlaces": enlaces[:10]}
with open("r23_resultado.json", "w") as f:
    json.dump(resultado, f, indent=2)
print(json.dumps(resultado, indent=2))
```

3. Prueba con al menos dos URLs distintas y observa los resultados.

Evidencias requeridas

- Screenshot del script completo.
- Screenshot de la ejecución con al menos una URL que devuelva resultados reales.
- Screenshot del archivo `r23_resultado.json` generado.

Preguntas de reflexión

1. Este scraper usa el `User-Agent` de Firefox para evitar ser bloqueado. ¿Es eso ético? ¿En qué situación cruzaría la línea entre investigación legítima y evasión maliciosa?
2. El regex de correos puede tener falsos positivos. ¿Qué tipo de cadena que no es un correo podría pasar ese filtro, y cómo lo mejorarías?

3. ¿Qué diferencia hay entre este scraper manual y una API oficial de OSINT (como la de Shodan o VirusTotal)?