

R23

GUIADO EN CLASE

Web scraper: descarga de imágenes de xkcd

Programacion para Ciberseguridad · Fase III · AD2026

El web scraping automatiza la recolección de contenido público de la web. En este reto practicas el flujo completo: instalar dependencias, generar URLs aleatorias, obtener y parsear HTML con BeautifulSoup, y descargar imágenes binarias — todo sobre un sitio real sin necesidad de autenticación.

Objetivo: Construir un script que descargue 3 imágenes de cómics aleatorios de xkcd.com, usando la API JSON para conocer el número máximo de cómics disponibles y BeautifulSoup para extraer el título y la imagen de cada página.

Instrucciones

1. Crea y activa un entorno virtual e instala las dependencias:

```
python3 -m venv entorno
source entorno/bin/activate      # Linux/macOS
# .\entorno\Scripts\Activate.ps1 # Windows PowerShell
pip install requests beautifulsoup4
```

2. Crea el archivo `r23_xkcd.py` con el siguiente código:

```
import requests
import random
import os
from bs4 import BeautifulSoup

if __name__ == "__main__":
    max_num = requests.get("https://xkcd.com/info.0.json").
    json()["num"]
    os.makedirs("xkcd", exist_ok=True)
    descargados = 0

    while descargados < 3:
        num = random.randint(1, max_num)
        resp = requests.get(f"https://xkcd.com/{num}/")
```

```

if resp.status_code != 200:
    continue

sopa = BeautifulSoup(resp.text, "html.parser")
titulo = sopa.find("div", id="ctitle").text.strip()
img = sopa.find("div", id="comic").find("img")
img_url = "https:" + img["src"]

ext = img_url.rsplit(".", 1)[-1]
ruta = f"xkcd/{titulo}.{ext}"

with open(ruta, "wb") as f:
    f.write(requests.get(img_url).content)

print(f"[OK] #{num} {titulo} -> {ruta}")
descargados += 1

```

3. Ejecuta el script y verifica que se creen 3 archivos en la carpeta `xkcd/`.

Evidencias requeridas

- Screenshot del script completo en el editor.
- Screenshot de la ejecución mostrando las 3 líneas `[OK] ....`
- Screenshot de la carpeta `xkcd/` con los 3 archivos y sus nombres visibles.

Preguntas de reflexion

1. El número máximo de cómics se obtiene con la API JSON de xkcd antes del bucle. ¿Por qué es importante consultarlo dinámicamente en vez de escribir un número fijo en el código?
2. Si el título del cómic contiene caracteres como `/` o `:`, el nombre del archivo fallará en algunos sistemas operativos. ¿Cómo lo resolverías con una sola línea de Python?
3. El bucle usa `while` en vez de `for`. ¿Por qué es más adecuado aquí, considerando que algunos números de cómic pueden no existir o devolver 404?